

VERİ ÖN İŞLEME

BETÜL TEMEL
ALİ DOĞUALP



Veri Setimizi Tanıyalım

Verinin Konusu: 1973 yılı, Mayıs ve Eylül ayları arasında New York'taki günlük hava kalitesi ölçümleri.

Boyut (Hacim): 153 satır (gözlem/gün) ve 6 sütun (değişken).

Değişkenler:

Ozone

Solar.R

Wind

Temp

Month

Day

	Ozone	Solar.R	Wind	Temp	Month	Day
1	41	190	7.4	67	5	1
2	36	118	8.0	72	5	2
3	12	149	12.6	74	5	3
4	18	313	11.5	62	5	4
5	NA	NA	14.3	56	5	5
6	28	NA	14.9	66	5	6
7	23	299	8.6	65	5	7
8	19	99	13.8	59	5	8
9	8	19	20.1	61	5	9
10	NA	194	8.6	69	5	10
11	7	NA	6.9	74	5	11
12	16	256	9.7	69	5	12
13	11	290	9.2	66	5	13
14	14	274	10.9	68	5	14
15	18	65	13.2	58	5	15
16	14	334	11.5	64	5	16
17	34	307	12.0	66	5	17
18	6	78	18.4	57	5	18
19	30	322	11.5	68	5	19
20	11	44	9.7	62	5	20

Showing 1 to 20 of 153 entries, 6 total columns


Eksik Veri Profili

- **Ozone (Ozon):** 37 adet eksik veri.
- **Solar.R (Güneş Radyasyonu):** 7 adet eksik veri.
- **Diğer Değişkenler:** Tamamen dolu (0 eksik).

Veri Kaybı Oranı: Toplam 153 gözlemimiz var. Ozon değişkenindeki 37 eksik, verinin yaklaşık %24'üne denk geliyor. Bu, basitçe "silip geçilemeyecek" kadar yüksek bir oran.

Sistemati mi, Rastgele mi? Ozon ve Güneş Radyasyonu değişkenlerindeki bu eksikler, muhtemelen ölçüm cihazlarındaki arızalardan veya o günkü hava koşullarından kaynaklanmış olabilir

Ön İşlemenin Gerekliliği: Eğer bu eksikleri yönetmezsek, kuracağımız modeller bu 37 satırı tamamen devre dışı bırakacaktır. Bu da ciddi bir bilgi kaybı demektir.



Toplam Kayıp Veri (NA): 37 (Ozone) + 7 (Solar.R) = 44
Kayıp Veri Yüzdesi = $(44/918) \times 100 = \%4.79$

Eksik Değer Doldurma Yöntemleri

1. Silme Yöntemi (Listwise Deletion)

- **Nedir?** İçinde en az bir tane NA olan tüm satırı veri setinden tamamen atmadır.
- **Ne Zaman Kullanılır?** Veri setin çok büyükse ve kayıp oranı çok düşükse (%1-2) tercih edilebilir.
- **Dezavantajı:** Bizim durumumuzda bunu yaparsak verinin %24'ü çöpe gider. Bilgi kaybı çok fazladır.

2. Ortalama/Medyan Atama (Mean/Median Imputation)

- **Nedir?** Boşlukları o sütunun ortalaması veya medyanı ile doldurmaktır.
- **Ne Zaman Kullanılır?** Hızlı ve pratik bir çözüm istendiğinde.
- **Dezavantajı:** Varyansı (çeşitliliği) yapay olarak düşürür. Grafikte ortada "sahte" bir tepe oluşturur.

3. Doğrusal Enterpolasyon (Linear Interpolation)

- **Nedir?** "Zaman serisi" mantığıdır. Boşluktan önceki ve sonraki değerleri düz bir çizgiyle birleştirip aradaki değeri tahmin eder.
- **Neden Bizim İçin Uygun?** Çünkü hava durumu verisi zamana bağlıdır. Dün 25, yarın 27 dereceseyse, bugün muhtemelen 26'dır.

Eksik Değer Doldurma Yöntemleri

4. K-En Yakın Komşu (KNN Imputation)


- **Nedir?** Makine öğrenmesi yöntemidir. "Bana arkadaşını söyle sana kim olduğunu söyleyeyim" mantığıyla çalışır.
- **Nasıl Çalışır?** Boşluğu olan bir günün rüzgarına ve sıcaklığına bakar, ona en benzeyen diğer 5 günü bulur ve o günlerin ortalamasını boşluğa yazar.

5. MICE (Çoklu Atama - Multiple Imputation)


- **Nedir?** İstatistikçilerin "altın standardı"dır.
- **Nasıl Çalışır?** Değişkenler arasındaki korelasyonu kullanır. Ozone değerini tahmin ederken Temp, Wind ve Solar.R değerlerini bir regresyon modeline sokarak en gerçekçi tahmini yapar.

Kayıp Veri Doldurma Yöntemlerinin Ayri Panellerde Kiyasi

Gri alan gercek veriyi, renkli çizgiler doldurma sonuclarini temsil eder.




Mean Imputation Grafiđi



Mean Imputation: En başarısız yöntemdir. Ozon ortalaması olan 40-50 ppb civarında devasa bir mor kule oluşturmıştır. Bu, verideki tüm varyansı (çeşitliliđi) öldürdüğümüzün ve her şeyi merkeze yığdığımızın görsel kanıtıdır.


İnterpolasyon Grafiği Yorumu



Interpolation: Dağılımın ana formunu korumuş ancak gerçek veriye (gri alan) kıyasla biraz daha "pürüzsüz" ve yayvan bir sonuç vermiştir. Uç değerlerdeki (yüksek ozon) keskinliği tam yakalayamamıştır.


KNN Grafiği Yorumu

KNN (k=5)



KNN k=5: Orijinal veriye oldukça yakın bir performans sergilemiştir. Gri alanın sınırlarını takip ederek, verinin doğal dalgalanmalarını başarılı bir şekilde yansıtmıştır.

MICE Grafiđi Yorumu



MICE: Grsel olarak en bařarılı yntemdir. Yeřil izgi, gri alanın hem merkezdeki yođunluđunu hem de sađa dođru uzanan kuyruk (skewness) yapısını neredeyse birebir kopyalamıřtır. Verinin istatistiksel karakterini en iyi bu yntem korumuřtur.

Ortalama ve Standart Sapma

Karşılaştırması

	Yontem	Ozone_Mean	Ozone_SD
1	Orijinal (NA'li)	42.12931	32.98788
2	Mean	42.12931	28.69337
3	Interpolation	43.29085	31.87826
4	KNN	40.75163	30.68951
5	MICE	42.13725	31.61114

Sadece ortalamaya bakmak bizi yanıltabilir. Basit ortalama atama (Mean) her ne kadar ortalamayı korusa da, standart sapmayı düşürerek veriyi 'fakirleştirmiş' ve varyansı öldürmüştür. MICE ise hem orijinal ortalamaya sadık kalmış hem de varyansı (SD) en gerçekçi seviyede koruyarak, analizimizin devamı için en güvenilir veri setini sunmuştur."

Korelasyon Analizi (Değişken İlişkileri)

Veri setimizde Ozon ile Sıcaklık (Temp) arasında güçlü bir ilişki vardır. Hangi yöntem bu "doğal bağı" bozmadı? Orijinal veride sıcaklık arttıkça ozon da artıyorsa, doldurulmuş veride de bu korelasyonun benzer kalması gerekir.

	Ozone	Solar.R	Wind	Temp	Month	Day
Ozone	1.000	0.348	-0.612	0.699	0.143	-0.005
Solar.R	0.348	1.000	-0.127	0.294	-0.074	-0.058
Wind	-0.612	-0.127	1.000	-0.497	-0.194	0.050
Temp	0.699	0.294	-0.497	1.000	0.404	-0.097
Month	0.143	-0.074	-0.194	0.404	1.000	-0.009
Day	-0.005	-0.058	0.050	-0.097	-0.009	1.000

	Yontem	Korelasyon
1	Original (NA'siz)	0.6983603
2	Mean	0.6087420
3	Interpolation	0.6016359
4	KNN	0.6723688
5	MICE	0.6589211

Basit doldurma yöntemleri (Mean ve Interpolation), değişkenler arasındaki ilişkiyi 0.69'dan 0.60 seviyelerine çekerek verinin 'bilimsel tutarlılığını' bozmuştur. Ancak KNN ve MICE, bu ilişkiyi başarıyla korumuştur.

RMSE Mantığı: "Yapay Boşluk"

Deneyi

Orijinal verideki NA değerlerinin gerçekte ne olduğunu bilemediğimiz için RMSE hesaplayamayız. Bu yüzden bir deney kurguluyoruz:

- Verideki tamamen dolu satırları ayırıyoruz.
- Bu satırlardan rastgele 20 tanesini (sanki yokmuş gibi) biz siliyoruz.
- Yöntemlerimizle bu sildiğimiz yerleri tahmin ettiriyoruz.

Tahminimiz gerçek değerden ne kadar saptı? İşte bu sapmanın adı RMSE'dir. (Sayı ne kadar küçükse, yöntem o kadar başarılıdır).

	Metot	RMSE_Skoru
1	Mean Imputation	25.43318
2	Interpolation	23.62050
3	KNN	12.13560
4	MICE	18.55704

SONUÇ

Değerlendirme Kriteri	Mean (Ortalama)	Interpolation	KNN (k=5)	MICE
Görsel Dağılım	Başarısız (Yapay kule)	Orta (Pürüzsüz)	İyi (Gerçekçi)	Mükemmel
Varyans (SD) Koruma	%13 Kayıp (Zayıf)	Başarılı	Başarılı	Çok Başarılı
Korelasyon Sadakati	Düşük (0.608)	En Düşük (0.601)	En Yüksek (0.672)	Yüksek (0.658)
RMSE (Hata Payı)	En Yüksek (25.43)	Yüksek (23.62)	En Düşük (12.13)	Düşük (18.55)
GENEL SONUÇ	Tavsiye Edilmez	Orta Seviye	Çok Başarılı	Çok Başarılı

Tüm testlerimizin (Görsel Dağılım, Standart Sapma, Korelasyon ve RMSE) sonucunu birleştirdiğimizde karşımıza net bir tablo çıkıyor:

Mean Imputation hem varyansı öldürüyor hem de hata payı en yüksek olan yöntem. MICE ve KNN ise hem verinin istatistiksel yapısını koruyor hem de en düşük hata ile gerçeğe en yakın değerleri üretiyor. Bu veri seti için en güvenilir analiz sonuçlarına KNN veya MICE ile ulaşabileceğimiz matematiksel olarak kanıtlanmıştır.

SCALE

YÖNTEMLERİ

1.Min-Max Scaling (Normalization)

Veriyi belirli bir aralığa (genelde 0–1) sıkıştırır.

Avantaj:

- Tüm değerler aynı aralıkta olur
- Sinir ağları için çok iyi

Dezavantaj:

- Aykırı değerlere (outlier) çok duyarlı

2. Standardization (Z-Score Scaling)

Veriyi ortalaması 0, standart sapması 1 olacak şekilde dönüştürür.

Avantaj:

- İstatistiksel analizlerde çok kullanılır
- Aykırı değerlere Min-Max'e göre daha dayanıklı

Dezavantaj:

- Belirli bir aralığa getirmez

3. Robust Scaling

Medyan ve IQR (çeyrekler arası aralık) kullanır.

Avantaj:

- Aykırı değerlere karşı en dayanıklı yöntemlerden biri

Dezavantaj:

- Veri dağılımını tam standartlaştırmaz

4. Max Abs Scaling

Veriyi maksimum mutlak değere bölerek ölçekler.

Avantaj:

- Negatif değerleri korur
- Sparse (seyrek) veriler için iyi

5. Log Scaling (Log Dönüşümü)

Verinin logaritması alınır.

Avantaj:

- Sağa çarpık dağılımları düzeltir
- Büyük değerleri küçültür

Not:

- Negatif ve sıfır değerlerde direkt uygulanamaz

6. Unit Vector Scaling (Normalization by Norm)

Her gözlemi birim vektör haline getirir.

Kullanım:

- Metin verisi (TF-IDF)
- Cosine similarity hesapları

Min-Max Uygulaması

```
===== MIN-MAX =====  
> print(head(df_minmax))  
      Ozone  Solar.R    Wind    Temp  Month      Day  
1 0.23952096 0.5596330 0.3000000 0.2682927      0 0.00000000  
2 0.20958084 0.3394495 0.3315789 0.3902439      0 0.03333333  
3 0.06586826 0.4342508 0.5736842 0.4390244      0 0.06666667  
4 0.10179641 0.9357798 0.5157895 0.1463415      0 0.10000000  
5 0.10179641 0.9633028 0.6631579 0.0000000      0 0.13333333  
6 0.16167665 0.9663609 0.6947368 0.2439024      0 0.16666667  
> cat("\n===== Z-SCORE =====\n")
```

“Veriler 0 ile 1 aralığına getirilmiştir. Ancak aykırı değerlerin varlığı diğer gözlemlerin sıkışmasına neden olabilir.”

Z-Score Uygulaması

```
===== Z-SCORE =====  
> print(head(df_z))  
      Ozone      Solar.R      Wind      Temp      Month      Day  
1  0.00737816  0.008123588 -0.7259482 -1.1497140 -1.407294 -1.670019  
2 -0.15388733 -0.790889284 -0.5556388 -0.6214670 -1.407294 -1.557210  
3 -0.92796167 -0.446869853  0.7500660 -0.4101682 -1.407294 -1.444401  
4 -0.73444308  1.373103911  0.4378323 -1.6779609 -1.407294 -1.331592  
5 -0.73444308  1.472980520  1.2326091 -2.3118573 -1.407294 -1.218782  
6 -0.41191211  1.484077921  1.4029185 -1.2553634 -1.407294 -1.105973  
> cat("\n===== ROBUST =====\n")
```

“Veriler ortalaması 0 ve standart sapması 1 olacak şekilde standardize edilmiştir. Bu yöntem, değişkenlerin karşılaştırılmasını kolaylaştırır.”

Robust Uygulaması

```
==== ROBUST ====  
> print(head(df_robust))  
      Ozone  Solar.R      Wind      Temp Month      Day  
1  0.21951220 -0.1654676 -0.5609756 -0.9230769    -1 -1.0000000  
2  0.09756098 -0.6834532 -0.4146341 -0.5384615    -1 -0.9333333  
3 -0.48780488 -0.4604317  0.7073171 -0.3846154    -1 -0.8666667  
4 -0.34146341  0.7194245  0.4390244 -1.3076923    -1 -0.8000000  
5 -0.34146341  0.7841727  1.1219512 -1.7692308    -1 -0.7333333  
6 -0.09756098  0.7913669  1.2682927 -1.0000000    -1 -0.6666667  
> cat("\n==== MAX ABS =====\n")
```

Veriler medyan ve çeyrekler arası aralığa göre ölçeklenmiştir. Bu yöntem aykırı değerlere karşı daha dayanıklıdır ve bu veri seti için uygundur.”

Max Abs Uygulaması

```
===== MAX ABS =====  
> print(head(df_maxabs))  
      Ozone  Solar.R    Wind    Temp    Month    Day  
1 0.24404762 0.5688623 0.3574879 0.6907216 0.5555556 0.03225806  
2 0.21428571 0.3532934 0.3864734 0.7422680 0.5555556 0.06451613  
3 0.07142857 0.4461078 0.6086957 0.7628866 0.5555556 0.09677419  
4 0.10714286 0.9371257 0.5555556 0.6391753 0.5555556 0.12903226  
5 0.10714286 0.9640719 0.6908213 0.5773196 0.5555556 0.16129032  
6 0.16666667 0.9670659 0.7198068 0.6804124 0.5555556 0.19354839  
> cat("\n===== LOG =====\n")
```

“Veriler maksimum mutlak değere bölünerek -1 ile 1 aralığına getirilmiştir. Ancak aykırı değerlerden etkilenebilir.”

Log Scaling Uygulaması

```
==== LOG ====  
> print(head(df_log))  
      Ozone  Solar.R    Wind    Temp    Month    Day  
1  3.713572  5.247024  2.001480  4.204693  1.609438  0.0000000  
2  3.583519  4.770685  2.079442  4.276666  1.609438  0.6931472  
3  2.484907  5.003946  2.533697  4.304065  1.609438  1.0986123  
4  2.890372  5.746203  2.442347  4.127134  1.609438  1.3862944  
5  2.890372  5.774552  2.660260  4.025352  1.609438  1.6094379  
6  3.332205  5.777652  2.701361  4.189655  1.609438  1.7917595  
> cat("\n==== UNIT VECTOR ====\n")
```

“Veriye log dönüşümü uygulanarak çarpık dağılım azaltılmıştır. Ancak sıfır ve negatif değerler nedeniyle bazı gözlemler kaybolmuştur.”

Unit Vector Uygulaması


```
===== UNIT VECTOR =====  
> print(head(df_unit))  
      Ozone  Solar.R      Wind      Temp      Month      Day  
1 0.19922932 0.9232578 0.03595846 0.3255699 0.02429626 0.004859252  
2 0.25145331 0.8242081 0.05587851 0.5029066 0.03492407 0.013969628  
3 0.07169610 0.8902266 0.07528091 0.4421260 0.02987338 0.017924025  
4 0.05627467 0.9785539 0.03595326 0.1938350 0.01563185 0.012505482  
5 0.05492542 0.9825548 0.04363520 0.1708791 0.01525706 0.015257062  
6 0.08451850 0.9749813 0.04497592 0.1992222 0.01509259 0.018111108  
> head(df_unit)      # Unit vector
```

“Her gözlem birim vektör haline getirilmiştir. Bu yöntem değişkenlerin göreceli önemini ortaya koyar ancak istatistiksel yorum açısından sınırlıdır.”

Hangi Yöntem En Başarılı?

Tum Degiskenler Uzerinde Olceklendirme Etkisi

Farkli birimlerin (ppb, mph, F) ortak olcege donusumu



Uyguladığımız scale etme yöntemleri ile farklı birimlere sahip değişkenlerin ölçeklendirme ile nasıl "ortak bir dile" kavuştuğunu ispatlamaktadır.

Standardization veriyi 0 merkezinde toplarken, Min-Max 0-1 aralığına sıkıştırmakta; Log Scaling ise Ozone'un sağa çarpık yapısını düzelterek dağılımı normale yaklaştırmaktadır. Özetle bu dönüşüm, sayısal büyüklük farklarını ortadan kaldırarak her değişkenin modele adil ve "demokratik" bir şekilde katkı sunmasını sağlar.

Hangi Yöntem En Başarılı?

Ölçekleme yöntemlerinin başarısı doğrudan ölçülemez. Ancak farklı ölçekleme yöntemleri uygulanarak aynı model kurulup performans ölçütleri (örneğin RMSE) karşılaştırılarak en uygun yöntem belirlenebilir.

```
> print(sonuc)
```

	Yontem	RMSE
1	Raw (MICE)	19.8285926
2	MinMax	0.1187341
3	Z-score	0.6395335
4	Robust	0.4836242
5	MaxAbs	0.1180273
6	Log	0.4858603

Eksik veriler MICE yöntemi ile tamamlandıktan sonra farklı ölçekleme yöntemleri uygulanmış ve her bir yöntem için kurulan regresyon modelinin RMSE değerleri karşılaştırılarak en başarılı yöntem belirlenmiştir.

```
en_iyi <- sonuc[which.min(sonuc$RMSE),  
print(en_iyi)  
Yontem      RMSE  
MaxAbs 0.1180273
```


SONUÇ

Analiz sonucunda en düşük RMSE değeri Max Abs Scaling yönteminde elde edilmiştir. Bunun temel nedeni, eksik verilerin MICE yöntemi ile doldurulması sonucunda veri setinin daha dengeli hale gelmesidir. Bu durumda, veriye güçlü dönüşümler uygulayan Z-score ve Robust Scaling yöntemleri yerine, verinin yapısını bozmayan Max Abs Scaling daha başarılı sonuç vermiştir. Ayrıca doğrusal regresyon modeli ölçekten bağımsız olduğu için, sadece oransal küçültme yapan bu yöntem model performansını olumlu etkilemiştir.